



Инфосистемы
Джет

MLSECOPS

Обеспечение ИБ на всех этапах
жизненного цикла ML-систем

Антон Конопак
Дмитрий Полторак

mlsecops@jet.su

2026

Искусственный интеллект в РФ



■ Развитием ИИ, проблемами доверия к ИИ и безопасностью ИИ озабочены на всех уровнях руководства РФ

Указ Президента № 490 — «О развитии искусственного интеллекта в Российской Федерации» определил **Национальную стратегию развития искусственного интеллекта** на период до 2030 года

Приказ ФСТЭК №117 (Требования о защите информации, содержащейся в ГИС) содержит требования к ГИС, **в составе которых есть ИИ**


Типовое техническое задание на выполнение работ по оценке уровня защищённости информационной инфраструктуры от **Минцифры** содержит требования к анализу ИИ-систем (раздел 4.7)

Методический документ ФСТЭК «Состав и содержание мероприятий и мер по защите информации, содержащейся в информационных системах» содержит мероприятия по обеспечению защиты информации **при использовании искусственного интеллекта**


Методические рекомендации Банка России по обеспечению информационной безопасности **при разработке и применении искусственного интеллекта** на финансовом рынке

ГОСТ Р 71476-2024 — Национальный стандарт. Искусственный интеллект. Концепции и терминология искусственного интеллекта. И еще **более 140 ГОСТов** по темам ИИ-систем и их защите


ML-модели: ИБ-проблематика, статистика




Наличие как **уникальных** для ML-моделей угроз ИБ, так и **классических**

 **29%**

Средний ежегодный прирост научных статей о методах и атаках на ML-модели за прошедшие 3 года (~ с 6 500 до 14 000 статей)*

 **30**

Стабильно развивающихся **инструментов для проведения атак** на ML-модели находятся в открытом доступе



Повсеместное внедрение **агентов и мультиагентных систем**, способных влиять на информационное окружение и друг друга

* По результату запроса Adversarial attack на агрегаторе препринтов научных статей <https://arxiv.org> с 01.06.2023 по 01.06.2026

ИИ-системы. Что и когда нужно защищать





Инфосистемы
Джет

ИИ и ИБ, ВОЗМОЖНЫЕ КОМБИНАЦИИ

ИБ в разработке ИИ

ИБ для работающего ИИ


ИИ для нужд ИБ
(ассистенты, агенты,
выполняющие задачи по ИБ)

Эта область
НЕ РАССМАТРИВАЕТСЯ
в рамках презентации

Что такое MLSecOps?



Цели MLSecOps




- Набор практик обеспечения и управления ИБ на всех этапах жизненного цикла ML-систем
- Дополнение к MLOps
- Настройка над DevSecOps
- Конфиденциальность данных и ML-моделей
- Целостность данных, кода и ML-моделей
- Доступность ML-систем
- Защита ИТ-инфраструктуры и ML-систем от атак



Основные уникальные угрозы ИБ функциональных ML-моделей



Кража
ML-модели




Обход
логики работы
ML-модели




DoS-атаки
на ML-модель


Нарушение
логики работы
ML-модели




Кража конфиденциальной
информации, входящей
в обучающую выборку



Проникновение
в ИТ-инфраструктуру
компании



Основные уникальные угрозы ИБ агентов и мультиагентских систем



Примеры реальных атак на ML-модели
MITRE ATLAS™ <https://atlas.mitre.org/studies>

Основные объекты защиты DevSecOps , MLSecOps



ОКРУЖЕНИЕ РАЗРАБОТКИ 02

Безопасная настройка ИС, используемых для автоматизации процесса разработки

КОМПОНЕНТЫ 01


Анализ ПО во время разработки и устранение ИБ-дефектов

03 СРЕДА ЭКСПЛУАТАЦИИ

Контроль настроек информационной безопасности и средств защиты в среде эксплуатации

04 ПРИЛОЖЕНИЕ

Контроль активности запущенного ПО и его защита



Основные объекты защиты DevSecOps , MLSecOps



ОКРУЖЕНИЕ РАЗРАБОТКИ

Безопасная настройка ИС, используемых для автоматизации процесса разработки

02

КОМПОНЕНТЫ

01

Анализ ПО во время разработки и устранение ИБ-дефектов

ДАННЫЕ

01

Обучающие, тестовые, валидационные данные, базы знаний для RAG, векторные представления данных, память агентов

ML-МОДЕЛИ

02

Полученные извне и разработанные самостоятельно

03 СРЕДА ЭКСПЛУАТАЦИИ

Контроль настроек информационной безопасности и средств защиты в среде эксплуатации

04 ПРИЛОЖЕНИЕ

Контроль активности запущенного ПО и его защита

04 ПРИВИЛЕГИИ


Контроль привилегий, выданных агентам

03 ПОТОКИ ДАННЫХ

Входной и выходной потоки данных, взаимодействие между агентами



Общий взгляд на DevSecOps и MLSecOps*



XXX

Уклон в технику

XXX

Уклон в процессы


XXX

Практики MLSecOps

*<https://github.com/Jet-Security-Team/DevSecOps-Assessment-Framework>



Подробный* и упрощенный ML PIPELINE



* <https://arxiv.org/abs/2205.02302> — Machine Learning Operations (MLOps): Overview, Definition, and Architecture

Варианты использования / разработки ML-систем

Варианты использования / разработки ML-систем

1 Полный цикл разработки ML-моделей (например, YandexGPT или GigaChat)

2 Заимствованная разработка (например, взяли YandexGPT или DeepSeek и (опционально) дообучили)

3 Использование готовой ML-модели в виде сервиса (MLaaS). Например, в Яндекс Облаке


Необходимый набор мер



- Стадии обработки данных
- Стадии выбора и обучения ML-моделей
- Стадии развертывания и мониторинга ML-моделей

* - Опционально

Инструменты ИБ в ML PIPELINE







Инфосистемы
Джет

ИБ В РАЗРАБОТКЕ ИИ. MLSECOPS

Мероприятия обеспечения ИБ ML-моделей




Инструменты обеспечения ИБ ML-моделей



Мероприятия обеспечения ИБ ML-моделей



Инструменты обеспечения ИБ ML-моделей



Инструменты обеспечения ИБ ML-моделей



ИНСТРУМЕНТЫ ОБЕСПЕЧЕНИЯ ИБ ML-МОДЕЛЕЙ





Инфосистемы
Джет

ИБ ДЛЯ РАБОТАЮЩЕГО ИИ. MLSECOPS

МЕРОПРИЯТИЯ ОБЕСПЕЧЕНИЯ ИБ ML-МОДЕЛЕЙ



7

РАЗВЕРТЫВАНИЕ ML-МОДЕЛЕЙ

Ограничены количество и скорость запросов к ML-системам от пользователей и ИС через API, между агентами

Ввод и вывод LLM ограничен количеством символов, набором символов, форматами, форматированием

Изменяются параметры входных и выходных данных ML-систем (пред- и постобработка)

Мультимодальные ML-системы защищаются для каждой модальности отдельно

ML-модели не хранятся на конечных устройствах пользователей без производственной необходимости

ML-системы запускаются в изолированной сетевой среде

DoS-атаки
на ML-модель


(Цепной) обход логики
работы ML-модели

Кража
ML-модели

Проникновение
в ИТ-инфраструктуру
компании

Избыточные
привилегии
у агентов


МЕРОПРИЯТИЯ ОБЕСПЕЧЕНИЯ ИБ ML-МОДЕЛЕЙ



Мероприятия обеспечения ИБ ML-моделей



Мероприятия обеспечения ИБ ML-моделей



■ *Угрозы общего характера

Схема обеспечения ИБ функционирующей ML-модели





Инфосистемы
Джет

ИНСТРУМЕНТЫ В КОНВЕЙЕРЕ ML**SE**COPS

Инструменты обеспечения ИБ ML-моделей



Инструментов MLSecOps мало.
Значительная их часть
является OPEN SOURCE.

Чаще всего инструменты MLSecOps
не имеют удобного интерфейса и управляются
через CLI, либо вообще являются куском кода.

Выполняют узкую задачу и при определенных
условиях. Поэтому требуется большое количество
разных инструментов для закрытия всех потребностей.

Инструменты обеспечения ИБ ML-моделей



```
$ garak --config garak.yaml
garak LLM vulnerability scanner v0.12.0 ( https://github.com/NVIDIA/garak ) at 2025-08-13T15:46:53.022241
📄 logging to /root/.local/share/garak/garak.log
🔌 loading generator: REST: http://10.31.121.209:8080/v1/chat/completions
📄 reporting to /root/.local/share/garak/garak_runs/garak.742f036c-34d8-43aa-8018-23458761efbe.report.jsonl
👤 queue of probes: leakreplay.GuardianCloze
leakreplay.GuardianCloze base.TriggerListDetector: PASS ok on 9/ 9
📄 report closed :) /root/.local/share/garak/garak_runs/garak.742f036c-34d8-43aa-8018-23458761efbe.report.jsonl
📄 report html summary being written to /root/.local/share/garak/garak_runs/garak.742f036c-34d8-43aa-8018-23458761efbe.report.html
✔ garak run complete in 141.13s
Uploading artifacts for successful job
```

Garak

```
$ modelaudit scan ./models/ --blacklist "metadata" --format json --output modelaudit-scan-results.json
2025-08-15 13:21:27,811 - modelaudit.core - INFO - Scanning file: /builds/mlsecops/neural-networks/fashion-mnist/models/fashion_model.h5
Results written to modelaudit-scan-results.json
$ if grep -q '"severity":"critical"' modelaudit-scan-results.json; then echo "Critical security issues found!"; exit 1; fi
Uploading artifacts for successful job
```

Modelaudit

```
$ modelscan -p ./models/* --show-skipped
No settings file detected at /builds/mlsecops/neural-networks/fashion-mnist/modelscan-settings.toml. Using defaults.
Scanning /builds/mlsecops/neural-networks/fashion-mnist/models/fashion_model.h5 using modelscan.scanners.H5LambdaDetectScan model scan
--- Summary ---
No issues found! 🎉
Cleaning up project directory and file based variables
```

Modelscan

```
$ python3 scan-llamator.py
i Artifacts will be saved to: ./artifacts/LLAMATOR_run-2025-08-13_15-47-58
i Logging has been set up with debug level: 1
```

```
--      --      ---      -----      -----      ----
//    //    /    |    /    W    /    W_   _//   __ M   __
//    //    //    |    |    /    /    /    /    /    /    /
/_/_/_/_/_/_/_/_   _/_/_/_/_/_/_/_   _/_/_/_/_/_/_/_   _/_
/_/_/_/_/_/_/_/_   |/_/_/_/_/_/_/_   |/_/_/_/_/_/_/_   |/_
```

v3.3.0

Testing Configuration

```
Number of threads: 1
Logging enabled: True
Reports enabled: True
Report language: ru
```

Validating models and tests...

LLamator

LLM Guard

Инструменты обеспечения ИБ ML-моделей



Инструмент \ Угроза	(Цепной) обход логики ML-модели	Нарушение логики ML-модели	Кража конфиденциальной информации	Кража ML-модели	DoS-атаки на ML-модель	Проникновение в ИТ-инфраструктуру	Избыточные привилегии у агентов
Dataclean			✓				
Presidio			✓				
Arx			✓				
Alibi detect		✓					
Pandas		✓					
Seaborn		✓					
ART	✓	✓					
Modelscan						✓	
Safetensors						✓	
Modelaudit						✓	
Opacus			✓				
Diffprivlib			✓				
Appsec. GenAI	✓				✓		

Инструменты обеспечения ИБ ML-моделей



Инструмент \ Угроза	(Цепной) обход логики ML-модели	Нарушение логики ML-модели	Кража конфиденциальной информации	Кража ML-модели	DoS-атаки на ML-модель	Проникновение в ИТ-инфраструктуру	Избыточные привилегии у агентов
Privacy meter			✓				
Foolbox	✓						
LLamator	✓				✓		
Garak	✓				✓		
Promptfoo	✓				✓		
Hive trace red	✓				✓		
Cosign						✓	
Hive trace	✓			✓	✓		✓
Nemo GUARDRAILS	✓			✓	✓		
Guardrail	✓			✓	✓		
LLM guard	✓			✓	✓		
Sowa					✓	✓	
Ai.Firewall (inera security)	✓			✓	✓		✓

Инструменты обеспечения ИБ ML-моделей



Инструмент \ Модальность ML-модели	Текст	Аудио	Изображение
 Dataclean	Да	Нет	Нет
 Presidio	Да	Нет	Да
 Arx	Да	Нет	Нет
 Alibi detect	Да	Нет	Да
 Pandas	Да	Нет	Нет
 Seaborn	Да	Нет	Нет
 ART	Нет*	Да	Да
 Modelscan	Да	Да	Да
 Safetensors	Да	Да	Да
 Modelaudit	Да	Да	Да
 Opacus	Да	Да	Да
 Diffprivlib	Да	Да	Да
 Appsec.GenAI	Да	Да	Да

* Возможно ограниченное применение через конвертацию исходной модальности (в векторное представление, спектрограммы)

Инструменты обеспечения ИБ ML-моделей



Инструмент \ Модальность ML-модели	Текст	Аудио	Изображение
Privacy meter	Да	Нет*	Да
Foolbox	Нет*	Нет*	Да
LLamator	Да	Нет	Нет
Garak	Да	Да	Да
Promptfoo	Да	Да	Да
Hive trace red	Да	Нет	Нет
Cosign	Да	Да	Да
Hive trace	Да	Нет	Нет
Nemo GUARDRAILS	Да	Нет	Да
Guardrail	Да	Нет	Нет
LLM guard	Да	Нет	Нет
Sowa	Да*	Да*	Да*
Ai.Firewall (infera security)	Да	Нет	Нет

* Возможно ограниченное применение через конвертацию исходной модальности (в векторное представление, спектрограммы)



Инфосистемы
Джет

MLSECOPS. С ЧЕГО НАЧАТЬ?


Шаги выстраивания MLSECOPS. Концепт




Что делать



Аудит ИБ ML-систем



Моделирование угроз и анализ рисков ИБ ML-систем



Формирование и исполнение дорожной карты развития MLSecOps



Каким способом делать

Провести комплексный аудит:

- Процессов и инструментов обеспечения ИБ ML-моделей
- ML-систем
- ИТ- и сетевой инфраструктуры
- Средств защиты информации

Диаграммы потоков данных, STRIDE, OWASP GenAI Security Project, MITRE ATLAS, DREAD, ISO 27005, OWASP Risk rating и др.

Внедрить процессы и инструменты MLSecOps (для закрытия актуальных угроз и рисков ИБ)



Шаги выстраивания MLSECOPS. Детали

Инвентаризация существующих и разрабатываемых ML-моделей и систем.

Моделирование угроз и анализ рисков ИБ ML-систем

Разработать базовый комплект документов:

1. Политика ИБ ML-систем
2. Регламент процессов обеспечения и управления ИБ ML-систем
3. Регламент предоставления доступа работников компании к общедоступным ML-моделям
4. Метрики эффективности процессов обеспечения и управления ИБ ML-систем **и др.**

Провести анализ защищенности (пентест) для внедренных ML-моделей, выявить уязвимости и слабые стороны.

Устранить уязвимости, определить меры защиты внедренных ML-моделей, провести повторный анализ защищенности (пентест)

Пример типового выстраивания MLSecOps
(нет универсального подхода).

Внедрить:

- Сначала инструмент класса AI.Firewall (Guadrails).
Например, HiveTrace или Infera AI.Firewall
- Затем инструмент динамического (DAST) анализа ML-моделей. Например, HiveTrace Red, Garak или Appsec.GenAI
- Далее* инструменты
 - анализа и повышения робастности модели*.
Например, ART, Foolbox, Opacus, privacy meter и др.
 - анализа и фильтрации обучающих данных**.
Например, Dataclean, Alibidetector, ART
 - статического (SAST) анализа ML-моделей.
Например, modelaudit

* если организация заимствует и дорабатывает ML-модели. Слайд 14, компании из п.2

** если организация выстраивает полный цикл разработки ML-моделей (как, например, Яндекс или Сбер). Слайд 14, компании из п.1



Инфосистемы
Джет

РОССИЙСКИЕ РЕШЕНИЯ **AI FIREWALL**

Отечественные решения класса AI Firewall*



- Infera AI.Firewal
- Hivetrace
- AI Talon (AIGate)
- Страж
- VEAI (прокси)
- StarGuard AI от OrionSoft
- Checkpoint AI Guardrails (бывшая Lakera)
- Appsec.AIGate
- SolidWall от Яндекса и СолидЛаб
- Cyber Agent Review
- SOWA
- Lumi 42

* Порядок расположения в списке случаен и не несет никакого смыслового значения



Инфосистемы
Джет

УСЛУГИ ДЖЕТ В MLSECOPS



НАШИ УСЛУГИ

■
Аудит ИБ ML-моделей и инфраструктуры,
в которой ML-модели функционируют.
Анализ угроз ИБ ML-моделей

■
Разработка документов
по процессам MLSecOps, консалтинг

■
Внедрение, настройка,
интеграции инструментов MLSecOps

■
Формирование конвейера
MLSecOps «под ключ»

■
Анализ защищенности
(пентест) ML-моделей

■
Разработка ИИ-агентов
и ИИ-ассистентов



Инфосистемы
Джет

**СПАСИБО
ЗА ВНИМАНИЕ!**

Антон Конопак
Дмитрий Полторак
mlsecops@jet.su

2026



MLSecOps + DevSecOps
Assessment
Framework

<https://github.com/Jet-Security-Team/DevSecOps-Assessment-Framework>